PROYECTO FINAL · ENTREGA 1

Clasificación de lesiones cutáneas pigmentadas con redes neuronales convolucionales

Una comparación de modelos a partir del dataset HAM10000

Estudiante: Milton Alejandro Cuervo Ramirez · C.C: 1013587067
Programa: Ingeniería de Sistemas · Universidad de Antioquia
Profesores: Raúl Ramos y Julián Arias
Curso: Fundamentos de Deep Learning
Módulo 4: Convolutional Networks · Septiembre de 2026

1. ¿Qué se quiere estudiar?

Distinguir una lesión de piel de otra a partir de una imagen puede ser difícil: algunas comparten colores, formas y texturas, aunque correspondan a diagnósticos diferentes. En este proyecto se estudiará cómo una red neuronal convolucional, o CNN, aprende a reconocer esos patrones en imágenes dermatoscópicas. La dermatoscopia permite observar detalles de la piel que no se aprecian de la misma manera a simple vista.

El propósito es comparar distintas formas de construir y entrenar un clasificador, y entender qué ventajas y dificultades aparecen en cada una. Para ello se utilizará HAM10000, un conjunto de imágenes etiquetadas con siete categorías diagnósticas. El interés no estará solamente en obtener una cifra alta de aciertos, sino en identificar qué lesiones reconoce mejor el modelo, cuáles confunde y cómo influye la cantidad de ejemplos disponibles.

2. Objetivo y alcance

El objetivo general es comparar una CNN entrenada desde cero con VGG16, ResNet50 y EfficientNet-B0 preentrenadas, primero en una tarea de dos grupos y después en la clasificación de las siete categorías originales. Se mantendrán condiciones de evaluación comunes para que las diferencias observadas sean interpretables.

El resultado será un experimento académico reproducible: datos organizados, modelos entrenados, métricas comparables y un análisis de errores. Se trabajará con imágenes dermatoscópicas del dataset; evaluar fotografías tomadas con un celular o utilizar el sistema para tomar decisiones clínicas requeriría una validación adicional que no forma parte de esta entrega.

3. El dataset: qué contiene y por qué se eligió

HAM10000 reúne **10.015 imágenes dermatoscópicas**. Su nombre proviene de *Human Against Machine with 10000 training images*. Las imágenes proceden de centros de Austria y Australia y el conjunto fue utilizado en la tarea de clasificación de ISIC 2018. Esta diversidad de procedencias resulta útil para estudiar variaciones en la apariencia de las lesiones [1, 6].

Se utilizarán imágenes JPG en color, de 600 × 450 píxeles, junto con su archivo de metadatos. La entrada del modelo será la imagen y la respuesta que deberá aprender será su etiqueta diagnóstica. Los metadatos servirán para organizar, revisar y separar los datos; en el alcance inicial no se incorporarán como entradas adicionales de la red.

Código	Categoría diagnóstica	Imágenes	Porcentaje
nv	Nevos melanocíticos	6.705	66,95 %
mel	Melanoma	1.113	11,11 %
bkl	Lesiones benignas similares a queratosis	1.099	10,97 %
bcc	Carcinoma basocelular	514	5,13 %
akiec	Queratosis actínicas y carcinoma intraepitelial / enfermedad de Bowen	327	3,27 %
vasc	Lesiones vasculares	142	1,42 %
df	Dermatofibroma	115	1,15 %
Total	Siete categorías	10.015	100,00 %

El principal reto: las clases no están equilibradas

Hay 6.705 imágenes de nevos y solo 115 de dermatofibromas: aproximadamente 58 imágenes de la primera clase por cada una de la segunda. Por eso, un modelo podría acertar con frecuencia simplemente favoreciendo la categoría más abundante. Si siempre respondiera “nevo”, alcanzaría cerca del 67 % de exactitud, aunque no reconociera ninguna de las otras seis categorías.

Esta distribución convierte a HAM10000 en un conjunto apropiado para el proyecto: permite estudiar tanto las arquitecturas como las estrategias para aprender con clases poco representadas. La tabla muestra cantidades de imágenes, no de pacientes ni necesariamente de lesiones diferentes.

4. Cómo se interpretarán y organizarán los datos

Qué aporta el archivo de metadatos

Campo	Uso previsto en el proyecto
image_id	Vincular cada registro con su archivo de imagen.
lesion_id	Reconocer imágenes de una misma lesión y mantenerlas en una sola partición.
dx	Obtener la categoría que el modelo debe predecir.
dx_type	Revisar el método usado para establecer el diagnóstico de referencia.
age, sex, localization	Describir la muestra por edad, sexo y zona corporal, y revisar valores ausentes.

Una fila representa una imagen, pero una misma lesión puede aparecer en varias fotografías. Se utilizará **lesion_id** para que esas fotografías no queden repartidas entre entrenamiento y prueba. Este campo identifica lesiones; no permite asumir por sí solo que se han separado pacientes diferentes [1].

Más de la mitad de los casos se confirmaron por histopatología. Los demás se verificaron mediante seguimiento, consenso de expertos o microscopía confocal. Se revisará **dx_type** para describir esta diferencia en el origen de las etiquetas [1].

Cómo se construirá la tarea binaria

Para conservar la primera etapa del proyecto, se agruparán **mel, bcc y akiec** en una clase positiva de “lesiones malignas o premalignas”, con 1.954 imágenes (19,51 %). Las categorías **nv, bkl, vasc y df** formarán el grupo benigno, con 8.061 imágenes (80,49 %).

Esta denominación evita llamar malignos a todos los casos de **akiec**, una categoría que reúne queratosis actínicas y carcinoma intraepitelial. La agrupación se usará como una simplificación experimental; posteriormente se conservarán las siete etiquetas originales para estudiar las diferencias entre diagnósticos [1].

Acceso, revisión y condiciones de uso

La descarga se realizará desde la copia de Kaggle indicada en la propuesta, conservando la referencia al depósito original de Harvard Dataverse [6, 7]. Se comprobará que cada identificador tenga una imagen legible y una etiqueta válida. También se revisarán duplicados y metadatos incompletos. Los archivos originales se conservarán y cualquier exclusión quedará documentada. La licencia de los datos es CC BY-NC 4.0: requiere atribución y restringe el uso comercial [1].

5. Qué se hará antes de entrenar

Explorar los datos y definir las particiones

Primero se revisarán ejemplos de las siete clases, sus frecuencias y posibles problemas de calidad. Se observarán diferencias de iluminación, encuadre y presencia de elementos como vello. Esta exploración permitirá entender qué recibe realmente la red y justificar las decisiones de preparación.

Se propone destinar aproximadamente el **70 % al entrenamiento, el 15 % a validación y el 15 % a prueba**. La división se hará por lesión, procurando mantener la distribución de clases. Como se agruparán fotografías relacionadas, los porcentajes finales podrán variar ligeramente. Se registrarán los conteos por clase y se verificará que ninguna lesión aparezca en más de una partición.

El entrenamiento servirá para ajustar los pesos de la red. La validación permitirá elegir configuraciones y decidir cuándo detener el aprendizaje. La prueba permanecerá reservada hasta que esas decisiones estén cerradas. Se guardará la división y se reutilizará en todos los modelos para realizar una comparación consistente.

Preparar las imágenes

Se trabajará con imágenes RGB de **224 × 224 píxeles**. Se documentará el procedimiento de redimensionado y se revisará que conserve información relevante de la lesión. Para los modelos preentrenados se utilizará la normalización correspondiente a sus pesos de ImageNet.

Solo en entrenamiento se aplicarán transformaciones aleatorias, como giros, volteos y variaciones moderadas de brillo y color. El propósito es presentar distintas versiones de los ejemplos sin cambiar su etiqueta. Validación y prueba tendrán un procesamiento fijo, sin aumento aleatorio de datos, para que sus resultados puedan compararse.

Tratar el desbalance sin alterar la evaluación

Se compararán dos estrategias: dar mayor peso a las clases poco frecuentes en **CrossEntropyLoss** y utilizar **WeightedRandomSampler** para mostrarlas con mayor frecuencia durante el entrenamiento. Se evaluarán inicialmente por separado, ya que combinarlas sin comprobar su efecto puede compensar en exceso a las clases minoritarias.

Los pesos y las frecuencias de muestreo se calcularán únicamente con el conjunto de entrenamiento. Validación y prueba conservarán su distribución. Así se podrá comprobar si una mejora en las clases poco frecuentes se mantiene al evaluar imágenes que el modelo no utilizó para aprender.

6. Desarrollo del proyecto en tres etapas

Etapa 1. Construir una CNN desde cero

Se implementará en PyTorch una red con capas convolucionales, activaciones, reducción espacial mediante *max pooling* y una capa final para los dos grupos. Las convoluciones aprenderán patrones visuales; la reducción espacial disminuirá el tamaño de las representaciones y *dropout* ayudará a controlar el sobreajuste.

Esta primera red servirá para comprobar el flujo completo: lectura de imágenes, asignación de etiquetas, entrenamiento, validación y cálculo de métricas. Su resultado será la línea de base experimental. No se asumirá un F1 de referencia sin una fuente y unas condiciones de evaluación verificables.

Etapa 2. Comparar modelos preentrenados

Se evaluarán **VGG16, ResNet50 y EfficientNet-B0** sobre la misma tarea binaria. El aprendizaje por transferencia permite partir de pesos obtenidos previamente en ImageNet y adaptarlos al nuevo problema, en lugar de aprender todos los patrones desde el inicio.

VGG16 utiliza bloques de convoluciones con filtros pequeños; ResNet50 incorpora conexiones residuales que facilitan el entrenamiento de redes profundas; EfficientNet-B0 busca un equilibrio entre profundidad, anchura y resolución [3-5]. Se sustituirá la capa de salida de cada modelo y se entrenará primero el nuevo clasificador. Después se ajustarán capas adicionales con una tasa de aprendizaje menor.

Para comparar las arquitecturas se mantendrán las mismas particiones, métricas y reglas de selección. Se documentarán los hiperparámetros y el presupuesto de entrenamiento de cada experimento. La arquitectura elegida será la de mejor desempeño en validación según la métrica principal, considerando también sus errores y su costo computacional.

Etapa 3. Clasificar las siete categorías

La arquitectura seleccionada se adaptará para producir siete puntuaciones, una por diagnóstico. Se volverá a entrenar y evaluar esta configuración, manteniendo la separación por lesión. Esta etapa permitirá identificar confusiones que quedan ocultas al reunir varias categorías en un solo grupo.

Recursos y registro de los experimentos

Se utilizarán PyTorch y torchvision en una máquina local. Se probará un tamaño de lote inicial de 32 y se reducirá si la memoria disponible lo exige. El tiempo por época se medirá en el equipo real. Se guardarán las semillas, las versiones del entorno, los parámetros, las curvas de aprendizaje y el mejor estado de cada modelo según validación.

7. Cómo se evaluará y qué se entregará

La métrica principal será **balanced accuracy**, que promedia la sensibilidad de las clases y les da el mismo peso. Se acompañará de **F1 macro**, calculando primero F1 para cada clase y luego su promedio; **AUC-ROC** para la clase positiva en la tarea binaria y macro uno-contra-el-resto en multiclase; y matrices de confusión con cantidades y proporciones.

También se informará la sensibilidad por diagnóstico y la tasa de falsos negativos. El objetivo de superar el 85 % de sensibilidad para melanoma se conservará como **meta exploratoria, no como resultado garantizado**. En la tarea binaria se revisará qué proporción de melanomas llega al grupo positivo; en multiclase, qué proporción se identifica específicamente como melanoma. Cualquier ajuste de umbral se decidirá con validación.

Las curvas de pérdida y desempeño ayudarán a detectar sobreajuste. El informe final incluirá una tabla de comparación de modelos, tiempos medidos, matrices de confusión, ejemplos de errores y una explicación de las limitaciones. Las clases con pocos ejemplos requieren especial cautela, porque unos pocos errores pueden cambiar mucho sus métricas.

Esta entrega presenta el plan de trabajo; todavía no reporta modelos entrenados ni resultados propios. Se espera determinar qué enfoque ofrece el mejor equilibrio entre desempeño por clase y recursos, sin asumir que el modelo más complejo será necesariamente el mejor. Las conclusiones se limitarán a los datos y al protocolo evaluados.

8. Referencias

[1] Tschandl, P., Rosendahl, C. y Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data, 5*, 180161. doi:10.1038/sdata.2018.161.

[2] Esteva, A. et al. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature, 542*, 115-118. Antecedente del tema; sus resultados no se adoptan como una comparación directa con este proyecto. doi:10.1038/nature21056.

[3] He, K. et al. (2016). Deep Residual Learning for Image Recognition. *CVPR*. doi:10.1109/CVPR.2016.90.

[4] Simonyan, K. y Zisserman, A. (2014). Very Deep Convolutional Networks for Large-Scale Image Recognition. arXiv:1409.1556.

[5] Tan, M. y Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *ICML*. arXiv:1905.11946.

[6] Tschandl, P. HAM10000: datos y metadatos. Harvard Dataverse. doi:10.7910/DVN/DBW86T.

[7] Usuario kmader. Skin Cancer MNIST: HAM10000. Copia de acceso en Kaggle. kaggle.com/datasets/kmader/skin-cancer-mnist-ham10000.