INFORME DEL PROYECTO · ENTREGA FINAL

Clasificación de lesiones cutáneas pigmentadas con redes neuronales convolucionales

Comparación experimental sobre HAM10000

Milton Alejandro Cuervo Ramirez
Ingeniería de Sistemas · Universidad de Antioquia
Fundamentos de Deep Learning
Docentes: Raúl Ramos y Julián Arias
13 de noviembre de 2026

Resumen

Se evaluaron una CNN desde cero y tres arquitecturas con pesos de ImageNet para clasificar imágenes dermatoscópicas de HAM10000. Se conservaron 10.015 imágenes y se separaron entrenamiento, validación y test por **lesion_id**. La selección utilizó balanced accuracy de validación; el test reservado incluyó 1.494 imágenes. La CNN ponderada alcanzó balanced accuracy de **0,7865** y sensibilidad del grupo maligno o premaligno de **94,03 %**. ResNet50, seleccionada entre las arquitecturas preentrenadas, obtuvo 0,7585 y 77,04 %, respectivamente. En siete clases, ResNet50 con ajuste fino obtuvo balanced accuracy de **0,7123**, F1 macro de **0,5814** y sensibilidad exacta de melanoma de **61,50 %**. Las cifras proceden de ejecuciones completas y predicciones conservadas; no constituyen validación clínica.

Objetivo y alcance

Comparar una línea de base con VGG16, ResNet50 y EfficientNet-B0 en una tarea binaria, y reutilizar la arquitectura seleccionada en una tarea de siete clases. Se estudian el desbalance, la transferencia y el ajuste fino mediante un protocolo reproducible y compatible con el equipo local.

Tarea	Definición y criterio
Binaria	Positiva: mel, bcc y akiec; benigna: bkl, df, nv y vasc.
Multiclase	Siete diagnósticos originales; una categoría por imagen.
Selección	Máxima balanced accuracy de validación; test consultado después de fijar la selección.

La agrupación positiva reúne lesiones malignas o premalignas y no equivale a diagnosticar melanoma. El estudio mide comportamiento experimental dentro del conjunto disponible.

1. Datos, particiones y preprocesado

HAM10000 contiene 10.015 imágenes dermatoscópicas de siete categorías [1]. Se utilizó la distribución de Kaggle [5]. Hay 7.470 identificadores de lesión: una lesión puede aportar varias imágenes. La separación se hizo por lesión y con semilla 42, aproximadamente 70/15/15; el agrupamiento explica las pequeñas diferencias en proporción.

Clase	Descripción	Train	Val.	Test	Total
akiec	Queratosis actínica / carcinoma intraepitelial	207	57	63	327
bcc	Carcinoma basocelular	381	65	68	514
bkl	Lesión similar a queratosis benigna	741	206	152	1099
df	Dermatofibroma	89	19	7	115
mel	Melanoma	770	156	187	1113
nv	Nevus melanocítico	4718	991	996	6705
vasc	Lesión vascular	96	25	21	142
Total	Imágenes	7002	1519	1494	10015
Lesiones	lesion_id únicos	5229	1120	1121	7470

Los nevus representan el 66,95 % de las imágenes (6.705/10.015), frente a 115 dermatofibromas. El grupo positivo binario reúne 1.954 imágenes (19,51 %); en test hay 318 positivas y 1.176 benignas. Por ello, la exactitud global se complementa con métricas que conceden el mismo peso a cada clase.

Controles para evitar contaminación

Se comprobaron la correspondencia entre metadatos e imágenes, la lectura de los originales, la ausencia de lesiones compartidas y la ausencia de duplicados exactos por SHA-256 entre particiones. No se excluyeron imágenes. Las frecuencias para ponderar la pérdida se calcularon exclusivamente en train. La separación es **por lesión, no por paciente**; no permite asegurar independencia entre pacientes.

Transformaciones ejecutadas

Las imágenes se convirtieron a RGB y se redimensionaron a 224 × 224 mediante interpolación bilineal. Una caché PNG evita repetir esta preparación y conserva los originales. Solo train recibió volteos horizontal y vertical aleatorios y rotación de hasta 20°. Se aplicó normalización ImageNet: medias (0,485; 0,456; 0,406) y desviaciones (0,229; 0,224; 0,225). Validación y test no recibieron aumentos aleatorios.

La licencia declarada por la copia de Kaggle es CC-BY-NC-SA-4.0 [5]. El uso realizado es académico y debe conservar la atribución y las condiciones de esa distribución.

2. Diseño experimental ejecutado

Experimento	Arquitectura y entrenamiento
CNN desde cero	Tres bloques Conv 3×3–BatchNorm–ReLU–MaxPool, con 16/32/64 canales; pooling global, dropout 0,3 y salida de dos clases. 23.938 parámetros. Dos variantes: pérdida sin pesos y ponderada; 10 épocas cada una.
Transferencia binaria	VGG16 [2], ResNet50 [3] y EfficientNet-B0 [4], pesos IMAGENET1K_V1. Backbone congelado; cabeza de dos clases entrenada durante 5 épocas. VGG16 usa pooling global y una cabeza compacta.
ResNet50 multiclase	Inicialización ImageNet y cabeza nueva de siete clases: 8 épocas. Se recuperó el mejor checkpoint de cabeza y se ajustaron layer4 y la cabeza durante 5 épocas adicionales.

Configuración común

Se usaron Adam, batch 8, semilla 42 y precisión FP32. La tasa de aprendizaje fue 10^{-3} para la CNN y las cabezas, y 10^{-4} en el ajuste fino. Se mantuvo weight_decay = 0. No se usaron scheduler ni parada temprana: los presupuestos de épocas fueron fijos. Los backbones congelados se mantuvieron en modo de evaluación; solo los módulos entrenables actualizaron sus parámetros y estadísticas pertinentes.

La pérdida fue entropía cruzada. En las variantes ponderadas, el peso de cada clase fue **$w(c) = N / [K \cdot n(c)]$**, con N imágenes de train, K clases y n(c) ejemplos de esa clase en train. No se combinaron estos pesos con un muestreador ponderado.

Selección y evaluación

Cada época registró pérdida de train y validación, balanced accuracy y F1 macro de validación. El checkpoint se eligió por máxima balanced accuracy; en empates se conservó el primer máximo. La arquitectura binaria preentrenada se fijó con el mismo criterio. Test utilizó argmax de probabilidades y no se ajustaron umbrales con sus etiquetas. Solo los tres modelos finales seleccionados se evaluaron en test.

Balanced accuracy: promedio del recall por clase. **F1 macro:** promedio del F1 de cada clase. **AUC-ROC:** área bajo la curva binaria; en siete clases se calculó one-vs-rest (OvR), promedio macro. **FNR:** 1 − recall. La AUC mide ordenación de probabilidades y no garantiza una sensibilidad determinada en argmax.

Equipo y diferencias frente a la propuesta

La ejecución local utilizó NVIDIA GTX 1050 de 3 GB, Python 3.12, PyTorch 2.6.0 + CUDA 11.8 y torchvision 0.21.0. El batch se redujo de 32 a 8 por memoria. Se ejecutó la comparación de pérdidas sin/con pesos; el WeightedRandomSampler y las variaciones de brillo/color previstas no se incorporaron a la versión final. No se atribuyen resultados a estas alternativas no ejecutadas.

3. Entrenamiento y selección por validación

Experimento	Épocas	Mejor	BAcc	F1 macro	Minutos
CNN sin pesos	10	10	0.6955	0.6877	10.01
CNN con pesos	10	10	0.7492	0.6085	9.71
VGG16 · cabeza	5	4	0.7458	0.6117	15.40
ResNet50 · cabeza	5	3	0.7927	0.6901	9.38
EfficientNet-B0 · cabeza	5	4	0.7920	0.7054	5.74
ResNet50 · 7 clases, cabeza	8	3	0.5707	0.3942	15.21
ResNet50 · ajuste fino	5	5	0.7281	0.6154	13.61

BAcc y F1 corresponden al checkpoint elegido por BAcc, no al máximo independiente de cada métrica. “Mejor” es la época dentro de cada etapa. Los minutos suman entrenamiento y validación registrados por época; excluyen descarga, preparación e inicialización.

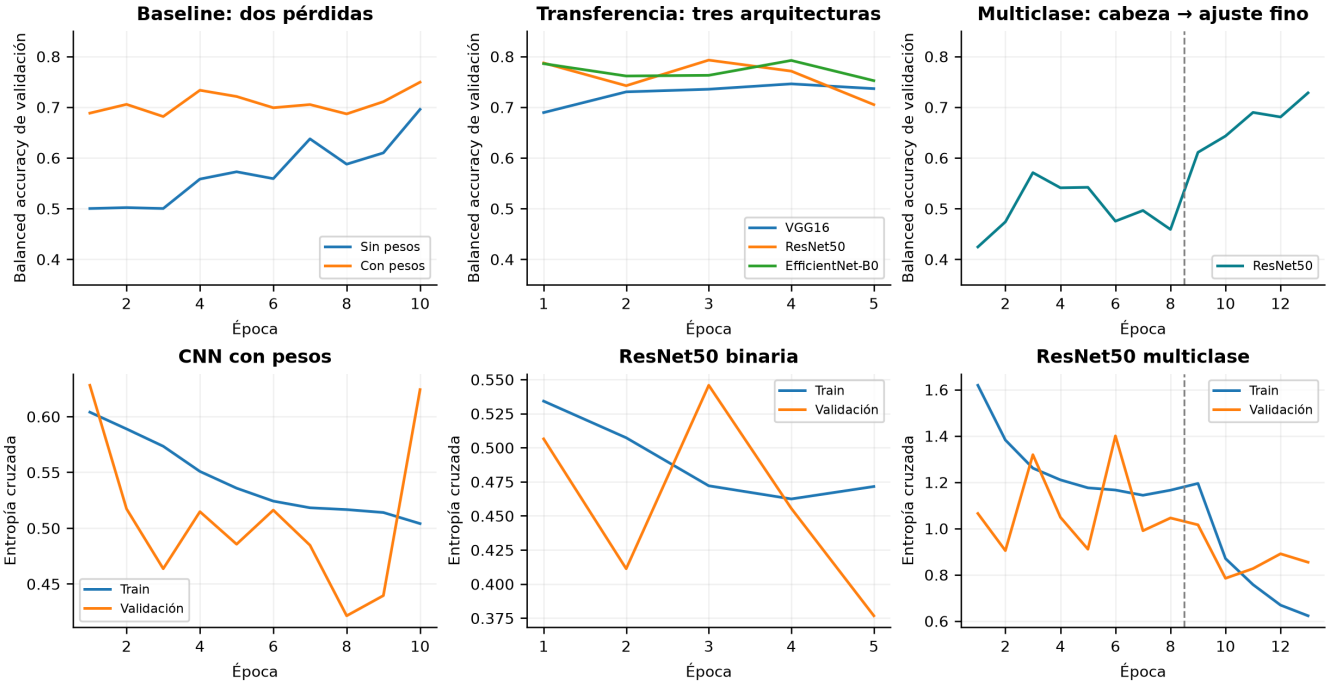


Figura 1. Arriba: balanced accuracy de validación de todas las variantes. Abajo: pérdidas de los modelos seleccionados. La línea vertical separa las 8 épocas de cabeza y las 5 de ajuste fino; este último arranca desde la mejor cabeza.

La ponderación elevó la BAcc de la CNN de 0,6955 a 0,7492, aunque redujo su F1 macro de validación. ResNet50 (0,7927) superó a EfficientNet-B0 (0,7920) por solo 0,066 puntos porcentuales: una diferencia insuficiente para afirmar superioridad estable con una única partición. Se conservó la regla de selección fijada.

El ajuste fino multiclase mejoró el mejor resultado de cabeza de 0,5707 a 0,7281. En esa etapa, la pérdida de validación mínima ocurrió antes del máximo de BAcc; la divergencia entre criterios justifica informar ambos, sin sustituir el criterio de selección por el último valor ni por la menor pérdida.

4. Test reservado: clasificación binaria

Los dos modelos seleccionados se evaluaron sobre las mismas 1.494 imágenes. La clase positiva agrupa mel, bcc y akiec. Las métricas siguientes se recalcularon desde los CSV de predicciones y coincidieron con los archivos de evaluación.

Modelo	BAcc	F1 macro	AUC-ROC	Exactitud
CNN ponderada	0.7865	0.6687	0.8649	0.6981
ResNet50	0.7585	0.6973	0.8483	0.7517

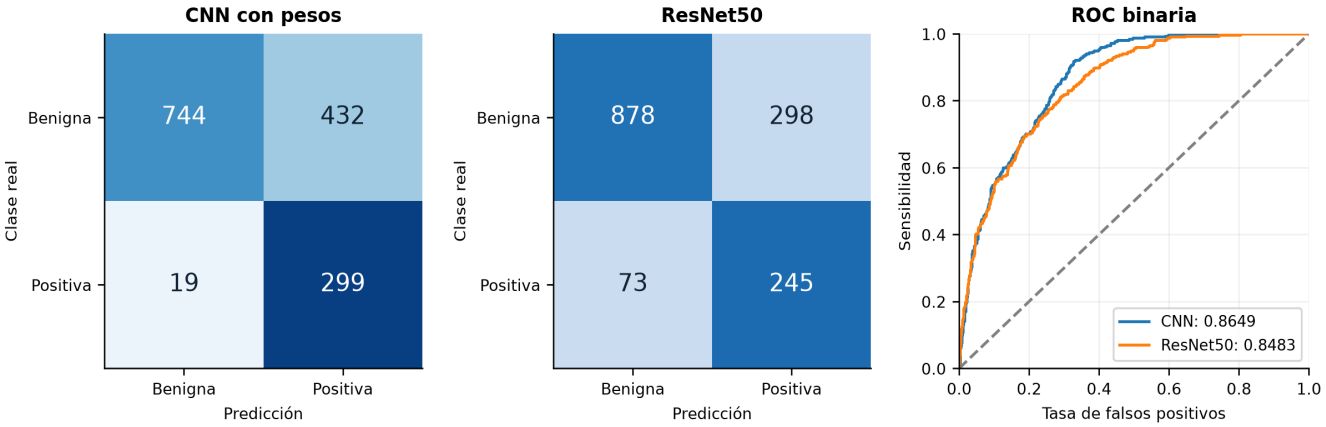


Figura 2. Matrices con recuentos absolutos y color normalizado por clase real; filas reales y columnas predichas. “Positiva” significa maligna o premaligna. La ROC recorre umbrales y no representa cambios aplicados a la predicción final.

Indicador del grupo positivo	CNN ponderada	ResNet50
Sensibilidad / recall	94,03 % (299/318)	77,04 % (245/318)
Especificidad	63,27 % (744/1.176)	74,66 % (878/1.176)
Precisión positiva	40,90 %	45,12 %
Falsos negativos / FNR	19 / 5,97 %	73 / 22,96 %
Falsos positivos	432	298

La CNN detectó más imágenes positivas y obtuvo mayor BAcc y AUC, a costa de 134 falsos positivos adicionales. ResNet50 logró mayor exactitud y F1 macro, pero dejó 54 positivos adicionales como benignos. Estas diferencias describen el test; no se cambió retroactivamente la selección por validación.

Melanoma dentro de la tarea binaria

De 187 imágenes con diagnóstico mel, la CNN asignó 175 al grupo positivo (**93,58 %**) y ResNet50 asignó 135 (**72,19 %**). La meta exploratoria de sensibilidad superior al 85 % se alcanzó con la CNN para esta **detección agrupada**. No implica reconocer melanoma como diagnóstico específico ni acredita rendimiento clínico.

5. Test reservado: siete categorías

ResNet50 con ajuste fino alcanzó **BAcc 0,7123 · F1 macro 0,5814 · exactitud 0,7309 · AUC OvR macro 0,9429**. La AUC multiclase no se compara directamente con la AUC binaria: resume un problema y una agregación diferentes.

Clase	Precisión	Recall	F1	FNR	n
akiec	0.5500	0.6984	0.6154	0.3016	63
bcc	0.5811	0.6324	0.6056	0.3676	68
bkl	0.4459	0.6513	0.5294	0.3487	152
df	0.1250	0.7143	0.2128	0.2857	7
mel	0.4792	0.6150	0.5386	0.3850	187
nv	0.9516	0.7701	0.8513	0.2299	996
vasc	0.5938	0.9048	0.7170	0.0952	21

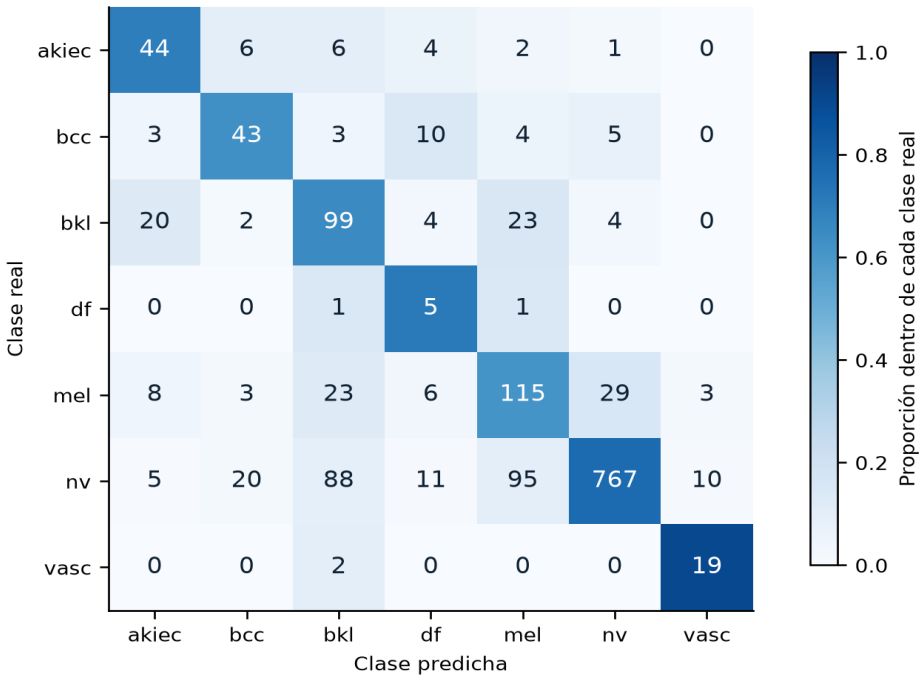


Figura 3. Matriz multiclase. Los números son recuentos absolutos; el color indica la proporción dentro de cada fila. El orden de clases coincide con la tabla.

Se reconocieron **115/187 melanomas (61,50 %)**; 72 se asignaron a otra clase, principalmente nv (29) y bkl (23). A su vez, 95 nevus se predijeron como melanoma. En df, acertar 5 de solo 7 ejemplos produjo recall 71,43 %, pero 40 predicciones totales de df redujeron su precisión al 12,50 %. La escasez de esa clase vuelve inestables sus estimaciones.

6. Conclusiones, límites y reproducibilidad

La ponderación mejoró la balanced accuracy de validación de la CNN y esta obtuvo la mayor sensibilidad binaria en test. La transferencia ofreció mejores F1 macro y exactitud binaria con ResNet50, sin superar la BAcc de la CNN. El ajuste fino de ResNet50 mejoró claramente la validación multiclase respecto a entrenar solo la cabeza, pero el F1 macro de test y los errores de melanoma muestran dificultades que la AUC macro elevada no elimina.

La meta de sensibilidad superior al 85 % solo se alcanzó para la inclusión del melanoma en el grupo positivo de la CNN binaria; no se alcanzó para el diagnóstico exacto de melanoma entre siete clases. Por ello, los resultados no justifican uso diagnóstico ni conclusiones clínicas.

Límites y trabajo futuro

El estudio usa una semilla y una partición, sin validación cruzada, intervalos de confianza ni evaluación externa. La separación por lesión no garantiza separación por paciente. Algunas clases tienen muy pocos ejemplos en test; además, se emplearon presupuestos cortos y backbones congelados en la comparación binaria. No se evaluaron calibración, umbrales clínicos ni el muestreador ponderado propuesto. Trabajos futuros deben medir variabilidad, estudiar calibración y confirmar el rendimiento con datos independientes; este test ya consultado no debe reutilizarse para optimizar decisiones.

Cómo reproducir y rastrear las cifras

Ejecutar los notebooks numerados 01 a 05 con el entorno descrito y los datos de HAM10000. El 02 fija las particiones; 03 y 04 guardan las selecciones binarias; 05 usa la arquitectura elegida y registra ambas etapas. Conservar test reservado durante nuevos experimentos. Los resultados de este informe corresponden al identificador **local_v2**, modo completo, no a las pruebas mínimas.

Evidencias locales: **data/splits/manifest_local.json** y **image_audit.csv**; historiales **results/full/local_v2/.../history.csv**; y **final_test/{baseline,transfer,multiclass}/**, con métricas y predicciones. Se contrastaron objetivos, probabilidades, matrices y métricas para las mismas 1.494 imágenes, además de las firmas de selección y checkpoints. En GitHub, los notebooks conservan tablas y figuras ejecutadas.

Código y salidas auditadas: MiltonCuervo/ham10000-skin-lesion-classification · commit e3438f9. La propuesta original se conserva como ENTREGA1.PDF.

Referencias

[1] Tschandl, P.; Rosendahl, C.; Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. Scientific Data, 5, 180161. doi:10.1038/sdata.2018.161.

[2] Simonyan, K.; Zisserman, A. (2015). Very Deep Convolutional Networks for Large-Scale Image Recognition. ICLR. arXiv:1409.1556.

[3] He, K.; Zhang, X.; Ren, S.; Sun, J. (2016). Deep Residual Learning for Image Recognition. CVPR, 770–778. doi:10.1109/CVPR.2016.90.

[4] Tan, M.; Le, Q. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. ICML, PMLR 97, 6105–6114. proceedings.mlr.press/v97/tan19a.html.

[5] Kaggle, kmader. Skin Cancer MNIST: HAM10000, distribución del conjunto. kaggle.com/datasets/kmader/skin-cancer-mnist-ham10000. Consulta: 13/11/2026.